

RDA-001 — Apuração de custo de IA (FinOps) no GABBI

Status: Proposed (pronto para CAB / governança)

Data: 14/01/2026

Escopo: Fase 1 — Custo (sem benefício/ROI por área)

Contexto

O GABBI precisa demonstrar, de forma auditável e em tempo próximo ao real, o custo do uso de modelos de IA. Há dois tipos de consumo coexistentes:

1. uso manual via front (colaborador)
2. uso automatizado via orquestração (agentes/fluxos)

Além disso, provedores/modelos aplicam **token mínimo** (e/ou custo mínimo) que impede calcular custo financeiro com fidelidade usando apenas “tokens por interação”.

Decisão

Adotar um modelo em 3 camadas para custo:

1. **Interaction (log bruto auditável)**
2. Registra eventos com tokens, modelo, ator e metadados necessários para auditoria. Não é fonte financeira.
3. **BillingAccumulator (acumulador por balde)**
4. Agrupa “sobras” de tokens por baldes de cobrança para respeitar token mínimo por modelo.
5. Baldes:
 - Manual: (Tenant, Model, CollaboratorId)
 - Automação: (Tenant, Model, TaskId)
6. **CostLedger (lançamento financeiro apropriado)**
7. Ao atingir o mínimo, gerar lançamentos financeiros já apropriados:
 - Manual: 1 linha → área do colaborador (sem rateio)
 - Automação: N linhas → rateio igualitário entre áreas pagadoras da task (detalhe de rateio entra na Fase 3)

Grafana e relatórios financeiros devem consultar exclusivamente o CostLedger.

Motivadores

- Auditabilidade (log bruto preservado)
- Acurácia financeira com token mínimo
- Evitar dashboards “recalculando custo” a cada consulta
- Preparar evolução incremental: custo → benefício → ROI

Consequências

Positivas

- Custo mensurado com rastreabilidade e consistência
- Fonte única de verdade financeira para dashboards
- Facilita governança e auditoria

Trade-offs

- Introduz estado (BillingAccumulator) e controle de concorrência
- Necessita idempotência para evitar lançamentos duplicados em retries

Requisitos técnicos derivados

- Lock transacional por balde no BillingAccumulator
- `idempotency_key` UNIQUE no CostLedger
- Tabela `ModelPricing` versionada (min_tokens/min_cost com vigência)
- Dashboards baseados em CostLedger (não Interaction)

Fora do escopo (Fase 1)

- Benefícios/receita por execução
- ROI por área / centro de custo
- Rateio por peso/ponderação
- Benefício variando por Flow

Critérios de aceite (Fase 1)

1. É possível visualizar no Grafana:

- custo total no período
- custo por origem (manual vs automação)
- custo por modelo

2. Ledger é consistente:

- soma de lançamentos = custo mínimo aplicado por fechamentos
- nenhum retry gera duplicidade (idempotência)

3. Interaction permanece auditável:

- cada evento que gera tokens foi registrado